

Data Augmentation y Transfer Learning

Deep Learning y Series de tiempo



Marco Teran
Universidad Sergio Arboleda

2023

Contenido

1 Data Augmentation

- Transformaciones de imágenes
- Parámetros de ImageDataGenerator

2 Transfer Learning

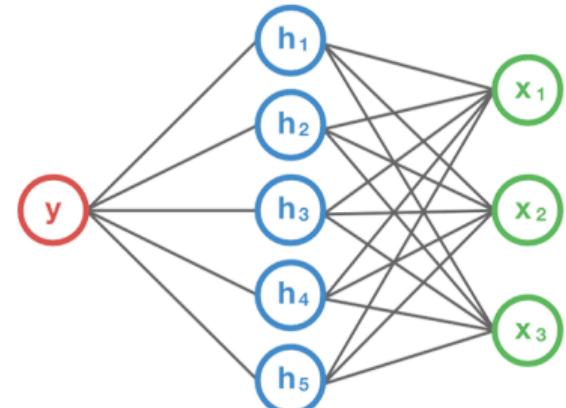
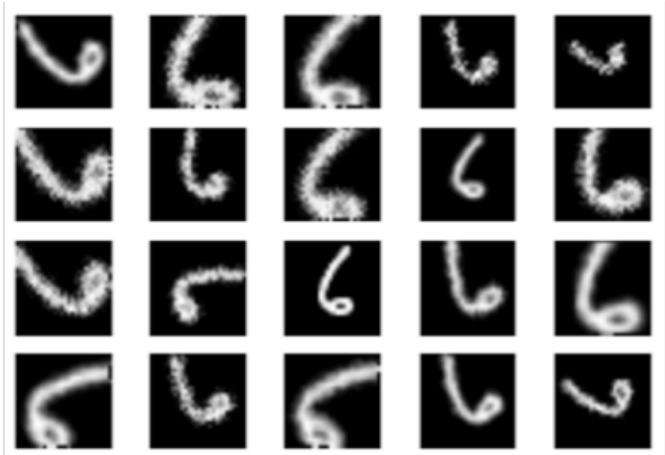
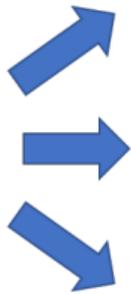
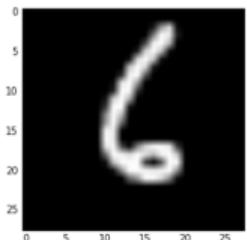
- Feature Extraction
- Fine-Tuning

Data Augmentation

Introducción

Introducción

- La mejora de la precisión de los modelos de Machine Learning es un aspecto clave para el éxito de la aplicación de esta tecnología en distintos ámbitos.
- Además de mejorar la precisión del modelo, el uso de Data Augmentation puede ayudar a prevenir el sobreajuste (overfitting), una situación en la que el modelo se ajusta demasiado bien a los datos de entrenamiento, lo que reduce su capacidad para generalizar correctamente.





Data Augmentation

Data Augmentation

La técnica de Data Augmentation consiste en la generación de nuevas muestras de datos a partir de las existentes, lo que permite incrementar el tamaño del conjunto de entrenamiento y mejorar la generalización del modelo.

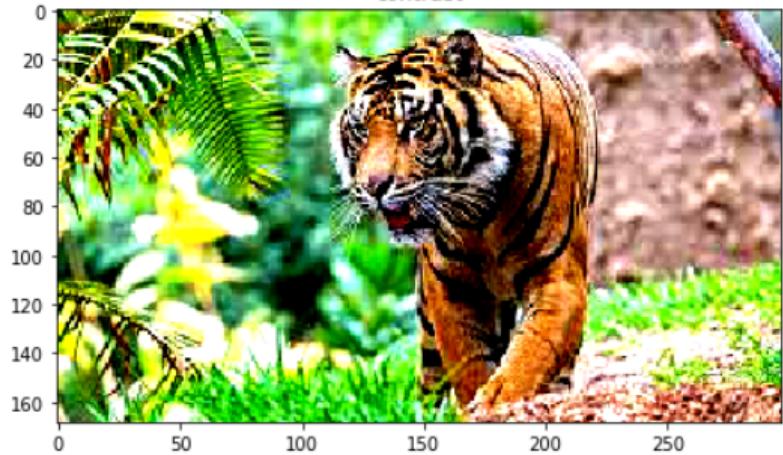
Data Augmentation

- Entre las técnicas más comunes de Data Augmentation se encuentran la rotación, el escalado, el cambio de contraste y la inversión de colores, entre otras.
- Es importante tener en cuenta que la selección de las técnicas adecuadas de Data Augmentation depende del tipo de datos y del problema específico que se esté abordando.

brightness



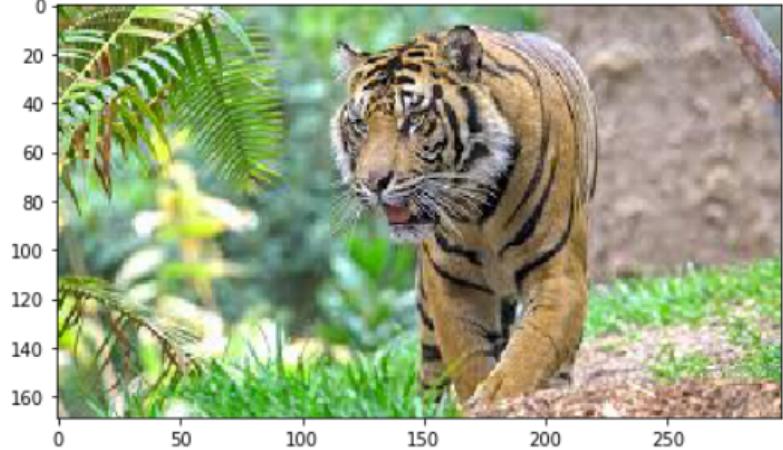
contrast



saturation



hue



Data Augmentation



Original Image



Augmented Images



Data Augmentation



Original Image



De-texturized



De-colorized



Edge Enhanced



Salient Edge Map



Flip/ Rotate

Transformaciones de imágenes

Transformaciones de imágenes

- Data Augmentation es una técnica poderosa para mejorar la precisión de los modelos de Machine Learning en datos de tipo imagen.
- Esta técnica aplica transformaciones sencillas como rotar o voltear imágenes para obtener nuevas imágenes plausibles en el conjunto de datos original.

Transformaciones de imágenes

- Es importante tener cuidado con la elección de las técnicas específicas de aumento de datos utilizadas para no generar imágenes que nunca podrían encontrarse en realidad.
- En Keras, se puede realizar la transformación fácilmente mediante la configuración de una serie de transformaciones en la instancia de `ImageDataGenerator`.

Transformaciones de imágenes

- Las transformaciones se realizan en línea durante el procesamiento, lo que permite hacer el proceso automático mientras se realiza el entrenamiento sin necesidad de modificar los datos almacenados en disco.
- Si las transformaciones se realizaran previamente, el preprocessado sería más rápido, pero el espacio de almacenamiento y el tiempo de carga de los datos en memoria serían más elevados.

Transformaciones de imágenes

- La API preprocessing de Keras proporciona información detallada sobre las transformaciones disponibles.
- Es importante tener en cuenta el contexto del conjunto de datos de entrenamiento y el conocimiento del dominio del problema al elegir las técnicas de Data Augmentation para mejorar el entrenamiento del modelo.

Parámetros de ImageDataGenerator


Parámetros de ImageDataGenerator

- ImageGenerator es una herramienta de Keras que permite crear lotes de imágenes de manera eficiente para el entrenamiento de modelos de aprendizaje profundo.
- Entre sus parámetros, se encuentra "rotation_range", que indica el rango de grados en que se pueden rotar las imágenes de forma aleatoria.
- También está el parámetro "width_shift_range", que indica el rango de píxeles en que se pueden desplazar horizontalmente las imágenes de forma aleatoria.
- Otro parámetro es "height_shift_range", que indica el rango de píxeles en que se pueden desplazar verticalmente las imágenes de forma aleatoria.

Parámetros de ImageDataGenerator

- El parámetro "shear_range" permite aplicar un sesgo de corte a las imágenes en un rango específico de grados.
- "zoom_range" permite realizar zooms aleatorios a las imágenes.
- "horizontal_flip" y "vertical_flip" son parámetros booleanos que indican si se debe voltear horizontal o verticalmente de forma aleatoria las imágenes.
- Por último, "fill_mode" especifica la estrategia de relleno que se utilizará para las transformaciones que cambien la forma o el tamaño de las imágenes.





Original



Rotation



Flip



Scaling



Brightness



Transfer Learning

Introducción

Introducción

- El Transfer Learning es una técnica fundamental en el campo del Deep Learning.
- Esta técnica nos permite ahorrar tiempo y recursos al no tener que entrenar una red neuronal desde cero.

Introducción


- Podemos descargar una red preentrenada y usar sus parámetros como punto de partida para continuar entrenando el modelo con nuestros propios datos.
- Si la red preentrenada se ha entrenado con un conjunto de datos lo suficientemente grande y general, sus características pueden resultar útiles para muchos problemas diferentes de visión por computadora.

Transfer Learning

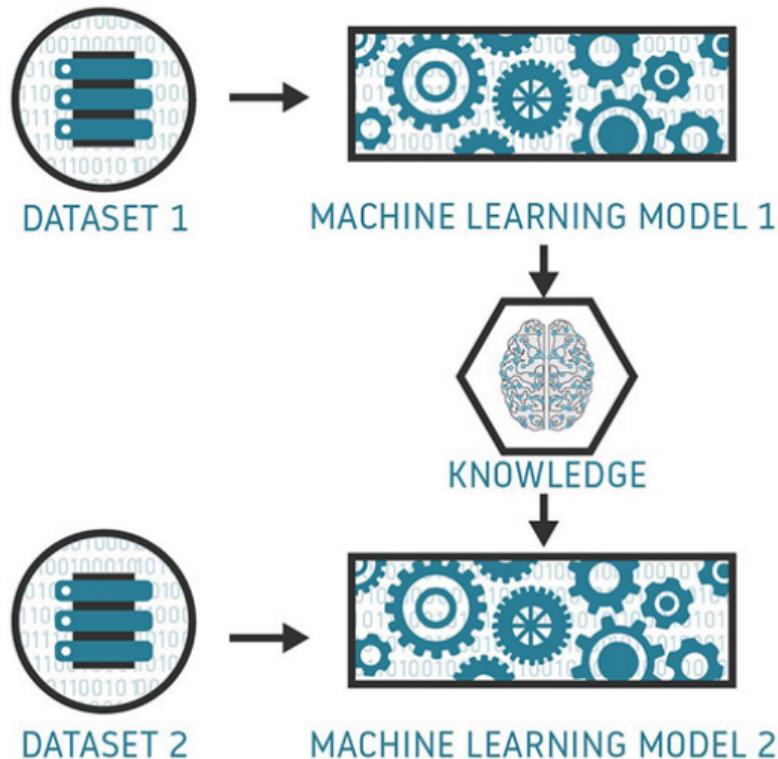
Transfer Learning

Transfer Learning es una técnica de aprendizaje automático que consiste en utilizar una red neuronal preentrenada en una tarea determinada como punto de partida para resolver otra tarea diferente, sin tener que entrenar una red neuronal desde cero. Esto nos permite ahorrar tiempo y recursos al utilizar los conocimientos previamente adquiridos por la red preentrenada, así como obtener mejores resultados con un conjunto de datos más pequeño.

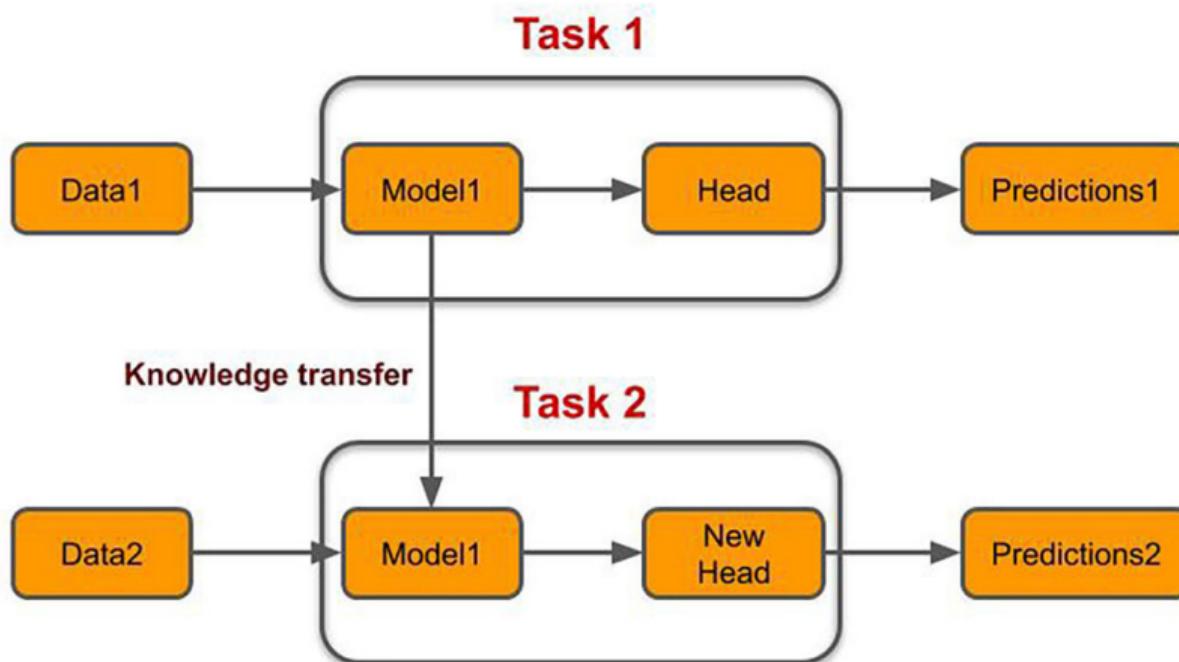
TRADITIONAL MACHINE LEARNING




TRANSFER LEARNING



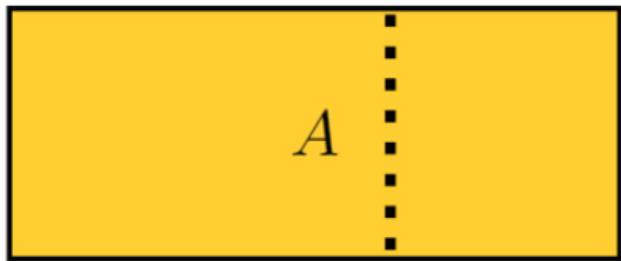
Transfer Learning



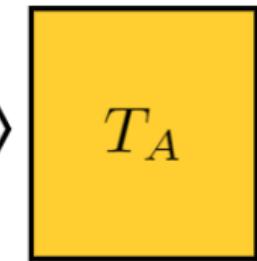
Generic dataset




Generic network



Generic task




Specific dataset





Pre-trained

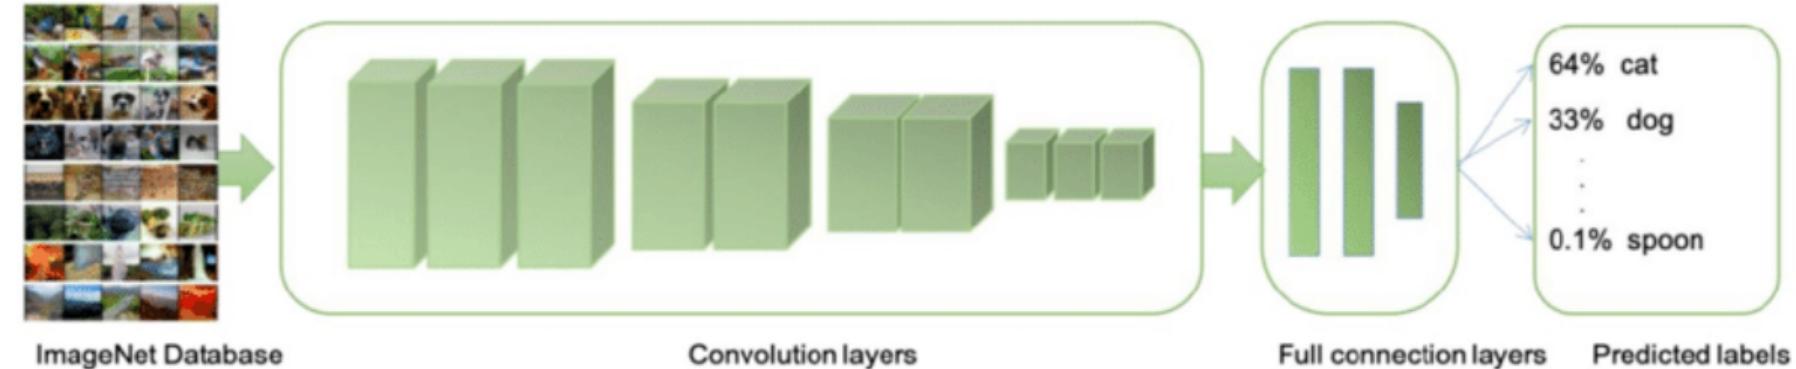


Trainable



Specific task






ImageNet Database Convolution layers Full connection layers Predicted labels


Trained Weights Transfer

Train from scratch



ImageNet Database Convolution layers Full connection layers Predicted labels

Training from Scratch



Principales características de Transfer Learning

- El Transfer Learning nos permite ahorrar tiempo y recursos al no tener que entrenar una red neuronal desde cero.
- Podemos descargar una red preentrenada y usar sus parámetros como punto de partida para continuar entrenando el modelo con nuestros propios datos.
- Las características aprendidas por la red preentrenada pueden resultar útiles para muchos problemas diferentes de visión por computadora.

Principales características de Transfer Learning

- Las primeras capas de la red preentrenada son las encargadas de aprender características más genéricas, las cuales pueden ser aplicables a otros problemas.
- Hay dos formas de utilizar una red preentrenada, Feature Extraction y Fine-Tuning, dependiendo de la cantidad de datos que tengamos y la complejidad de la tarea que queramos resolver.

Feature Extraction

Feature Extraction

Feature Extraction

Feature Extraction es un proceso en el cual se utilizan los parámetros aprendidos por una red preentrenada para extraer características relevantes de nuevos datos. Estas características se procesan a través de un nuevo clasificador que se entrena desde cero. La técnica se utiliza comúnmente en tareas de clasificación de imágenes.

Principales características del Feature Extraction

- Se utiliza para extraer características relevantes de nuevos datos, a partir de una red preentrenada.
- Consiste en la extracción de la base convolucional de una red preentrenada, que incluye sus capas de convoluciones y pooling.

Principales características del Feature Extraction

- La base convolucional aprende mapas de características genéricas sobre una imagen, lo que resulta útil para otros problemas del mismo ámbito.
- No se reutiliza el clasificador entrenado, ya que las representaciones aprendidas por el clasificador son específicas del conjunto de clases en las que se formó el modelo.


Principales características del Feature Extraction

- Las representaciones encontradas en capas densamente conectadas ya no mantienen información sobre dónde se encuentran los objetos en la imagen de entrada porque estas capas eliminan la noción de espacio, a diferencia de las capas convolucionales.
- La API de Keras permite aplicar esta técnica de una manera muy fácil y con pocas líneas de código.
- Keras permite descargar un modelo y luego configurar cómo este debe ser entrenado, indicando qué capas son entrenables y qué capas no.

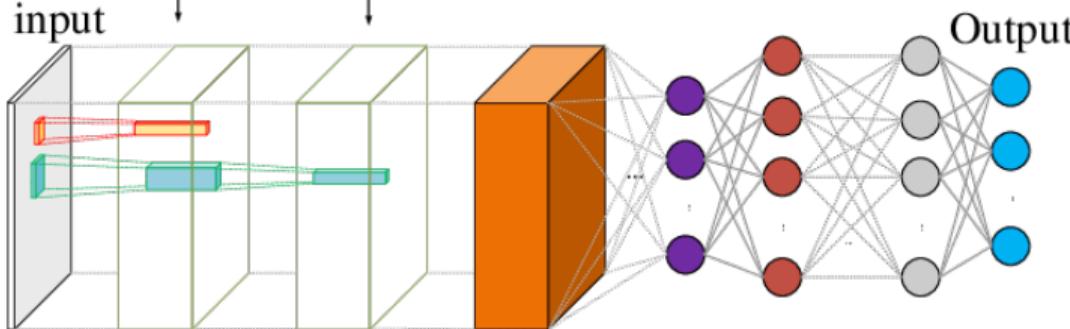
Principales características del Feature Extraction

- En general, se requieren varias iteraciones de prueba y error para descubrir la combinación correcta.
- Al aplicar Feature Extraction se obtienen características más relevantes y precisas que las obtenidas con un clasificador convencional.

Network A



Transfer
parameters



Network B

Fine-Tuning

Fine-Tuning

Fine-Tuning

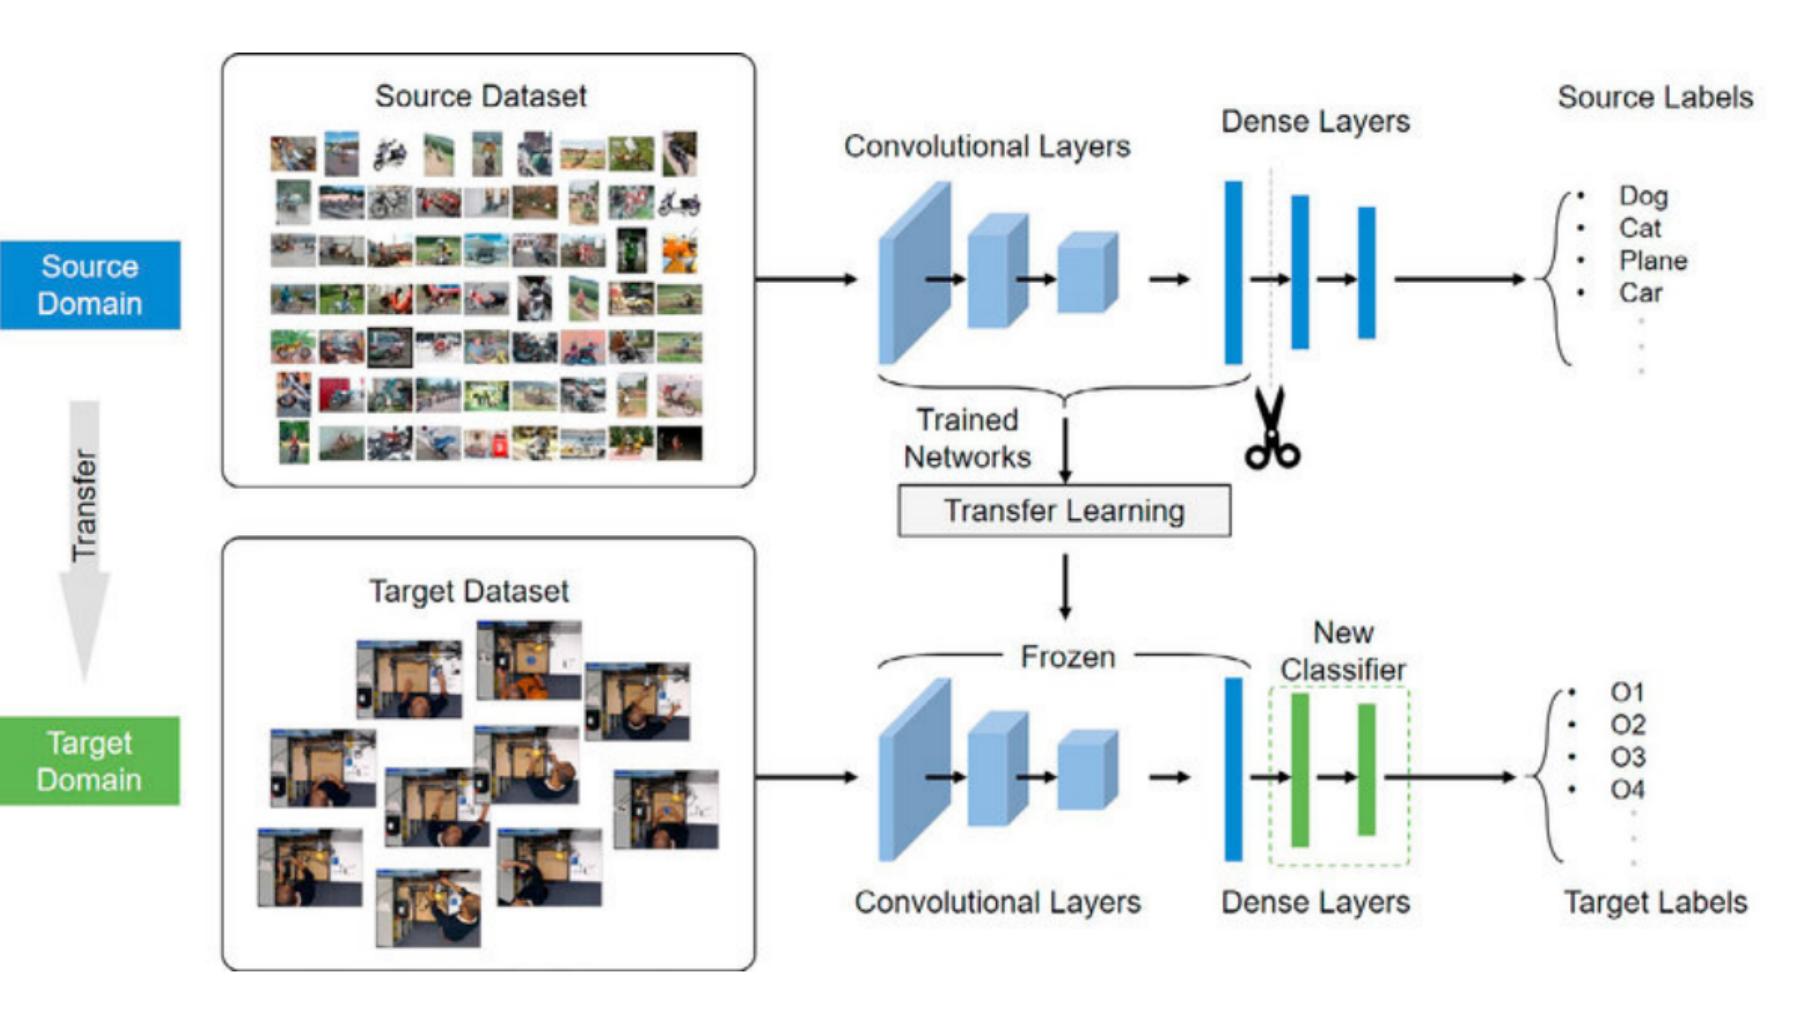
Fine-Tuning es una técnica de transfer learning ampliamente utilizada para ajustar un modelo pre-entrenado en un conjunto de datos diferente al que se entrenó originalmente. Se trata de un proceso complementario a la Feature Extraction, que implica el entrenamiento de algunas de las capas finales de la base convolucional del modelo utilizado para la extracción de características.

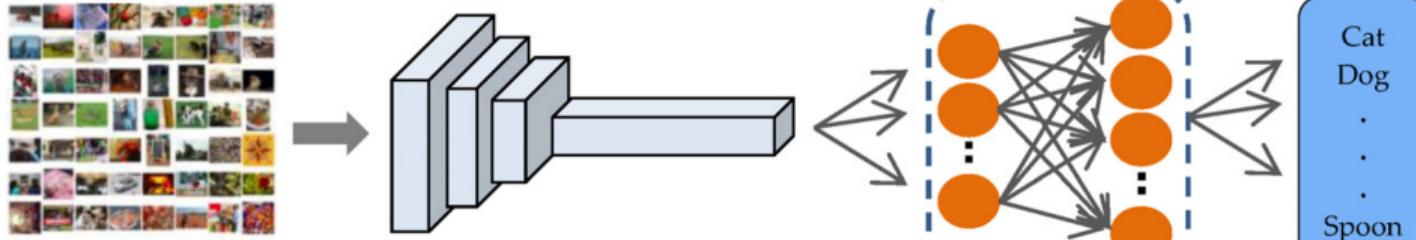
Principales características del Fine-Tuning

- El objetivo de Fine-Tuning es ajustar las representaciones más abstractas del modelo pre-entrenado que se está reutilizando como base.
- El nivel de generalización y reutilización de las representaciones extraídas por las capas de convolución específicas depende de la posición de la capa en el modelo pre-entrenado.

Principales características del Fine-Tuning

- Las primeras capas del modelo pre-entrenado aprenden características generales, mientras que las capas más cercanas al clasificador final extraen conceptos más abstractos.
- El proceso de Fine-Tuning puede ayudar a mejorar el rendimiento del modelo en el nuevo conjunto de datos al ajustar las características extraídas del modelo pre-entrenado a las características específicas del nuevo conjunto de datos.



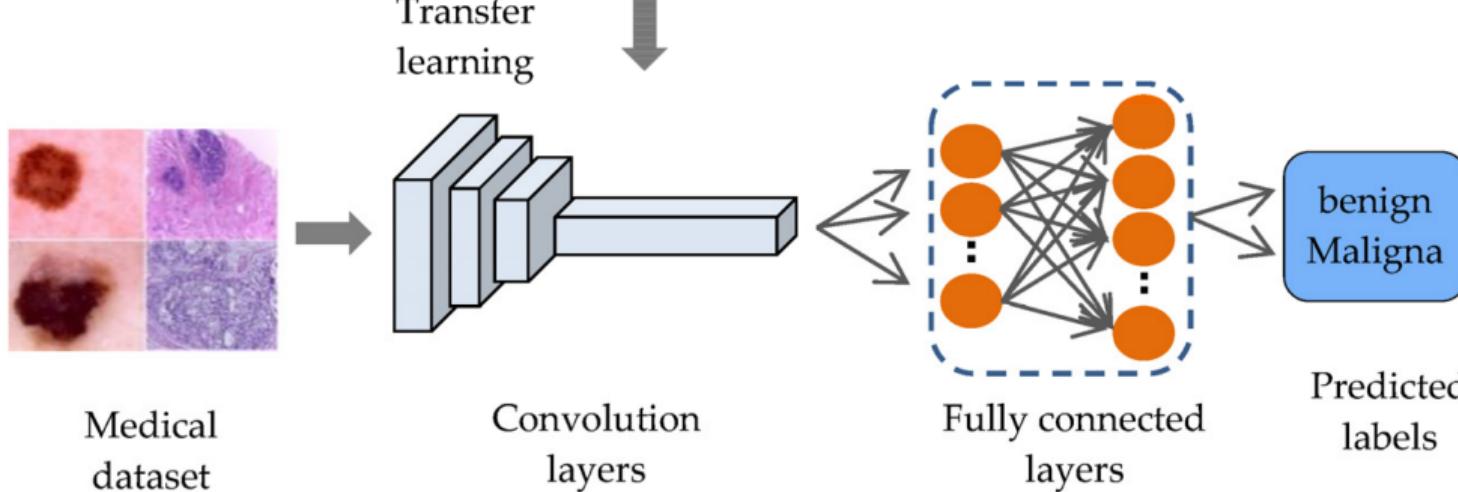


ImageNet
dataset

Convolution
layers

Fully connected
layers

Predicted
labels



Medical
dataset

Convolution
layers

Fully connected
layers

Predicted
labels

¡Muchas gracias por su atención!

¿Preguntas?



Contacto: Marco Teran
webpage: marcoteran.github.io/
e-mail: marco.teran@usa.edu.co

